Kredi Riski Skorlama ve Model Validasyonu

Kapsamli Proje Raporu

• Veri Seti: UCI - Default of Credit Card Clients (30,000 musteri)

• Modeller: Logistic Regression (Champion) + XGBoost (Challenger)

• Validasyon: ROC-AUC, KS, Gini, Kalibrasyon, PSI, SHAP

• Araclar: Python, SQL (DuckDB), scikit-learn, statsmodels, XGBoost

Mart 2026

Icindekiler

1. Giris: Kredi Riski ve Model Validasyonu Nedir?

2. Veri Seti Tanimi ve Degisken Sozlugu

3. Kesifsel Veri Analizi (EDA)

4. SQL ile Segment Analizleri

5. Feature Engineering (Degisken Turetme)

6. Model Gelistirme

7. Model Validasyonu

8. SHAP ile Model Yorumlama

9. Bulgular ve Oneriler

10. Mulakat Soru-Cevap Rehberi

11. Kavram Sozlugu

1. Giris: Kredi Riski ve Model Validasyonu Nedir?

1.1 Kredi Riski Nedir?

Kredi riski, bir bankanin borc verdigi kisinin veya kurumun bu borcu geri odeyememe olasiligini ifade eder. Ornegin bir banka size 10.000 TL kredi verdiginde, sizin bu parayi zamaninda geri odememeniz riski vardir. Iste bu risk, bankacilik sektorunun en temel risklerinden biridir ve 'kredi riski' olarak adlandirilir.

Bir banka icin kredi riskini yonetmek hayati onem tasir. Cunku bankalarin ana gelir kaynaklarindan biri faiz geliridir ve bu gelir ancak verilen kredilerin geri odenmesiyle gerceklesir. Eger cok sayida musteri borcunu odemezse (buna 'temerut' veya 'default' denir), banka ciddi zararlarla karsilasir. 2008 kuresel finans krizi, kredi riskinin yanlis yonetilmesinin ne kadar buyuk felaketlere yol acabileceginizin en carpici ornegidir.

> ***Temerut (Default):*** *Bir musterinin borc yukumlulugunu yerine getirememesi durumudur. Bu projede "default" olarak adlandirilan durum, kredi karti musterisinin bir sonraki ay odeme yapamamasi anlamina gelir.*

1.2 Bankalar Neden Kredi Riski Modeli Kullanir?

Bir bankanin milyonlarca musterisi vardir ve her biri icin kredi karari verilmesi gerekir. Insanlarin bu kararlari tek tek degerlendirmesi hem yavas hem de tutarsiz olur. Bu nedenle bankalar, istatistiksel ve makine ogrenmesi modellerini kullanarak her musteriye bir 'risk skoru' atar. Bu skor, musterinin temerude dusme olasiligini tahmin eder.

Kredi riski modelleri su amaclara hizmet eder:

- **Kredi karari:** Kredi verilsin mi, verilmesin mi?
- **Fiyatlandirma:** Riskli musteriye daha yuksek faiz uygulanmasi
- **Limit belirleme:** Musterinin kredi limitinin ne olmasi gerektigi
- **Sermaye yonetimi:** Basel duzenlenmelerine gore bankanin ne kadar sermaye ayirmasi gerektigi
- **Erken uyari:** Temerude dusebilecek musterilerin onceden tespit edilmesi

1.3 Model Validasyonu Nedir ve Neden Bu Kadar Onemlidir?

Model validasyonu, bir modelin gercekten dogru calisip calismadigini bagimsiz bir gozle denetleme surecidir. Bunu su sekilde dusunebilirsiniz: Bir muhendis kopru insa etti ve 'kopru saglam' dedi. Ama baska bir muhendis gelip bagimsiz olarak koprunun dayaniklilligini test etmeden o kopruye guvenebilir misiniz?

Model validasyonu da ayni mantikla calisir. Modeli kuran ekip 'model iyi calisiyor' dese bile, validasyon ekibi bagimsiz olarak su sorulari sorar:

- Model gercekten iyi ayristiriyor mu? (Riskli ve risksiz musterileri birbirinden ayirabiliyor mu?)
- Modelin urettigi olasiliklar gercekci mi? (Yuzde 30 risk dediginde gercekten 100 kisilik grupta 30 kisi default ediyor mu?)
- Model tum musteri segmentlerinde tutarli mi? (Gencler, yaslilar, yuksek limitliler...)
- Model zaman icinde bozuluyor mu? (Gecen yilki model hala gecerli mi?)
- Daha basit bir model ayni isi gorebilir mi? (Gereksiz karmasiklik var mi?)

Neden onemli? *Basel III ve BDDK duzenlenmelerine gore bankalar, kullandiklari modelleri duzenli olarak validate etmek zorundadir. Validate edilmemis bir model, hatali kredi kararlarina, sermaye yetersizligine ve nihayetinde regulator yaptirimlara yol acabilir.*

1.4 Bu Projenin Amaci

Bu projede, kredi karti musterilerinin temerude dusup dusmeyecegini tahmin eden bir model gelistirdik. Ancak projenin asil odagi sadece 'iyi bir model kurmak' degil, modeli validasyon bakis acisiyla degerlendirmektir. Proje boyunca:

- Veriyi anladik ve temizledik (Notebook 1-2)
- Iki farkli model kurduk: yorumlanabilir Logistic Regression ve guclu XGBoost (Notebook 3)
- Modelleri 7 farkli boyutta validate ettik: ayristirma gucu, kalibrasyon, decile, segment, kararlilik, yorumlama, champion vs challenger (Notebook 4)
- SQL ile segment bazli analizler yaparak bankacilik sektorunun beklentilerini karsildik

2. Veri Seti Tanimi ve Degisken Sozlugu

2.1 Veri Kaynagi

Bu projede UCI Machine Learning Repository'den alinan 'Default of Credit Card Clients' veri setini kullandik. Veri, Tayvan'daki bir bankanin 30.000 kredi karti musterisine aittir ve Nisan-Eylul 2005 arasindaki 6 aylik odeme gecmisini kapsar.

Veri setinin 'default payment next month' adli hedef degiskeni, musterinin bir sonraki ay temerrude dusup dusmedigini gosterir. Bu, tipik bir ikili siniflandirma (binary classification) problemidir.

Ozellik	Deger
Toplam musteri	30,000
Degisken sayisi	23 bagimsiz + 1 hedef
Donem	Nisan - Eylul 2005
Ulke	Tayvan
Default orani	%22.12 (6,636 musteri)
Non-default orani	%77.88 (23,364 musteri)

2.2 Degisken Sozlugu

Asagidaki tablo, veri setindeki her degiskenin ne anlama geldigini aciklar. Bu degiskenleri anlamak, hem modeli kurmak hem de sonuclari yorumlamak icin zorunludur.

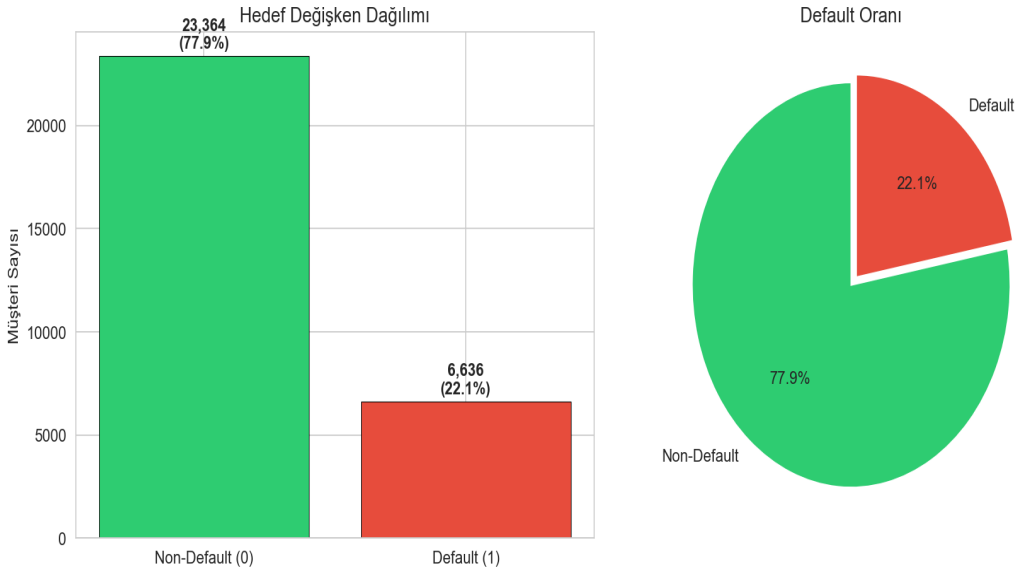
Degisken	Aciklama	Tip	Ornek Degerler
LIMIT_BAL	Kredi limiti (NT dolari)	Surekli	10,000 - 1,000,000
SEX	Cinsiyet	Kategorik	1=Erkek, 2=Kadin
EDUCATION	Egitim seviyesi	Kategorik	1=Lisansustu, 2=Uni, 3=Lise, 4=Diger
MARRIAGE	Medeni durum	Kategorik	1=Evli, 2=Bekar, 3=Diger
AGE	Yas	Surekli	21 - 79
PAY_0 - PAY_6	Odeme gecikme durumu (6 ay)	Ordinal	-2=Yok, -1=Zamaninda, 1+=Gecikme
BILL_AMT1-6	Ekstre tutarlari (6 ay, NT$)	Surekli	Negatif olabilir (fazla odeme)
PAY_AMT1-6	Odeme tutarlari (6 ay, NT$)	Surekli	0 ve uzeri
DEFAULT_FLAG	Temerut bayragi (hedef)	Ikili	0=Odedi, 1=Odemedi

PAY degiskenleri hakkinda onemli not: *PAY_0 en son ayin (Eylul), PAY_6 en eski ayin (Nisan) gecikme durumunu gosterir. -2 hesabin kullanilmadigini, -1 zamaninda odeme yapildigini, 0 asgari odeme (revolver) yapildigini, 1+ ise gecikme suresini (ay) belirtir. Bu degiskenler, modellerin en guclu sinyal kaynagi olacaktir.*

2.3 Hedef Degisken: Sinif Dengesizligi

Veri setinde default orani yaklasik %22'dir. Yani her 100 musteriden yaklasik 22'si borcunu odeyemez duruma dusmustur. Bu, 'sinif dengesizligi' (class imbalance) olarak adlandirilan bir durumdur.

Neden onemli? Eger model hic dusunmeden herkese 'default etmeyecek' derse, zaten %78 dogruluga ulasir. Ama bu ise yaramaz bir modeldir cunku hicbir riskli musteriyi tespit edemez. Bu nedenle modellemeye baslamadan once dengesizlik stratejileri uygulanmalidir (class_weight='balanced', scale_pos_weight gibi).



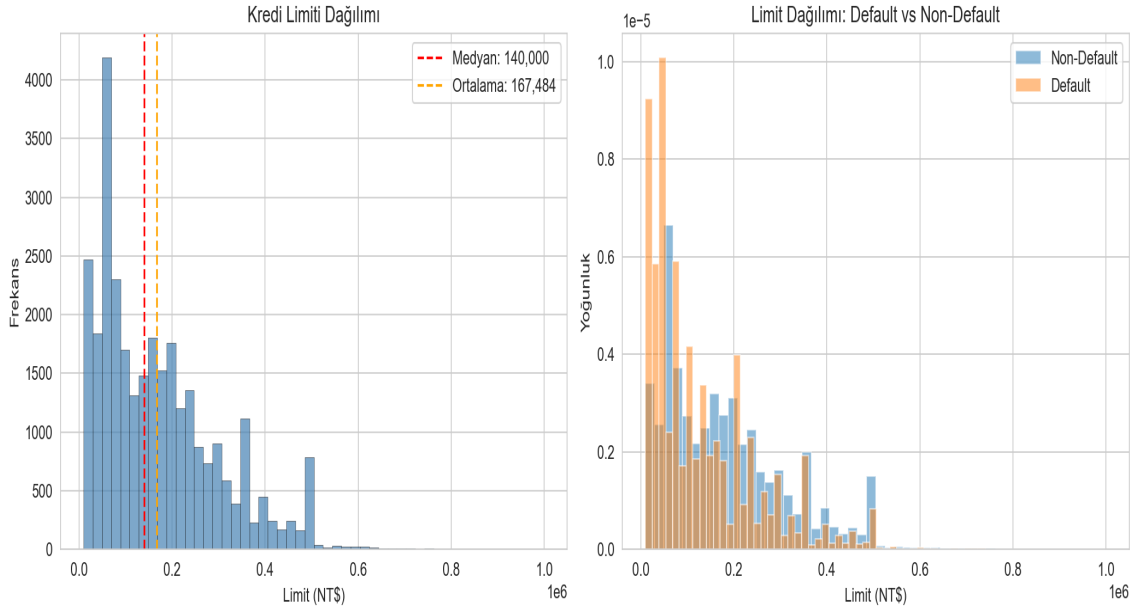
Sekil 2.1: Hedef degisken (default) dagilimi

3. Kesifsel Veri Analizi (EDA)

Kesifsel veri analizi (Exploratory Data Analysis - EDA), veriyi modellemeden once anlamaya calismaktir. Amac, verinin hikayesini kesfetmek ve 'bu veride hangi patternler var, hangi degiskenler default ile iliskili?' sorularini cevaplamaktir.

3.1 Kredi Limiti Dagilimi

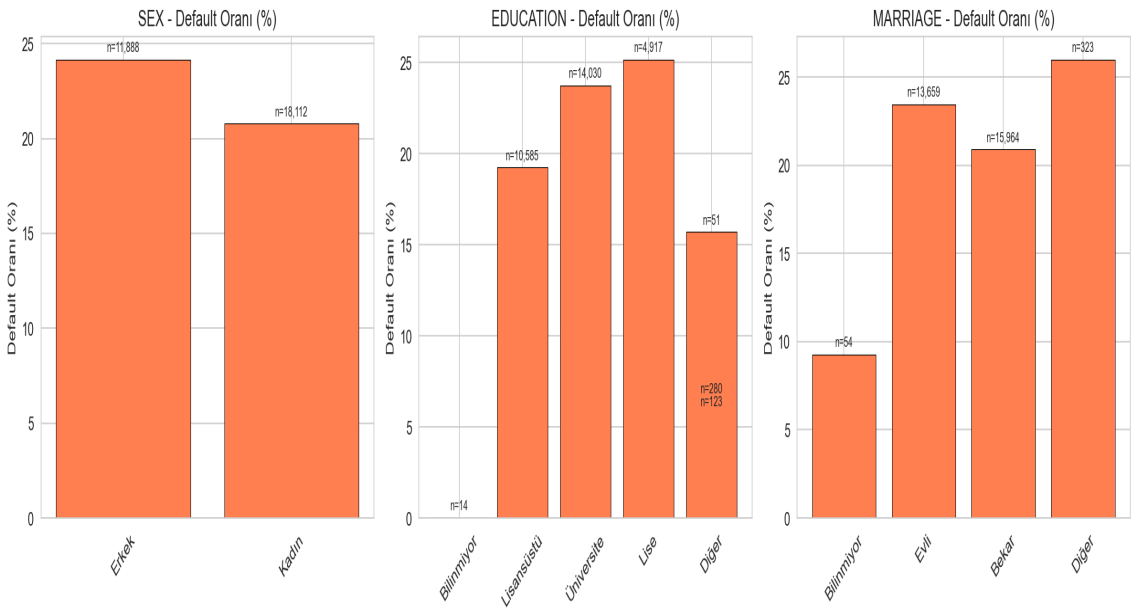
Kredi limiti, bir musterinin harcama tavanini belirler. Dusuk limitli musteriler genellikle daha riskli olarak degerlendirilir cunku bankanin onlara sinirli guven verdigi anlamina gelir.



Sekil 3.1: Kredi limiti dagilimi ve default karsilastirmasi

Grafik bize iki onemli sey soyluyor: (1) Limit dagilimi saga carpiktir — cogu musteri dusuk-orta limitlerde yogunlasmistir. (2) Default eden musteriler genellikle daha dusuk limitlerde yogunlasmistir. Bu, limitin guclu bir risk sinyali oldugunu gosterir.

3.2 Demografik Analizler

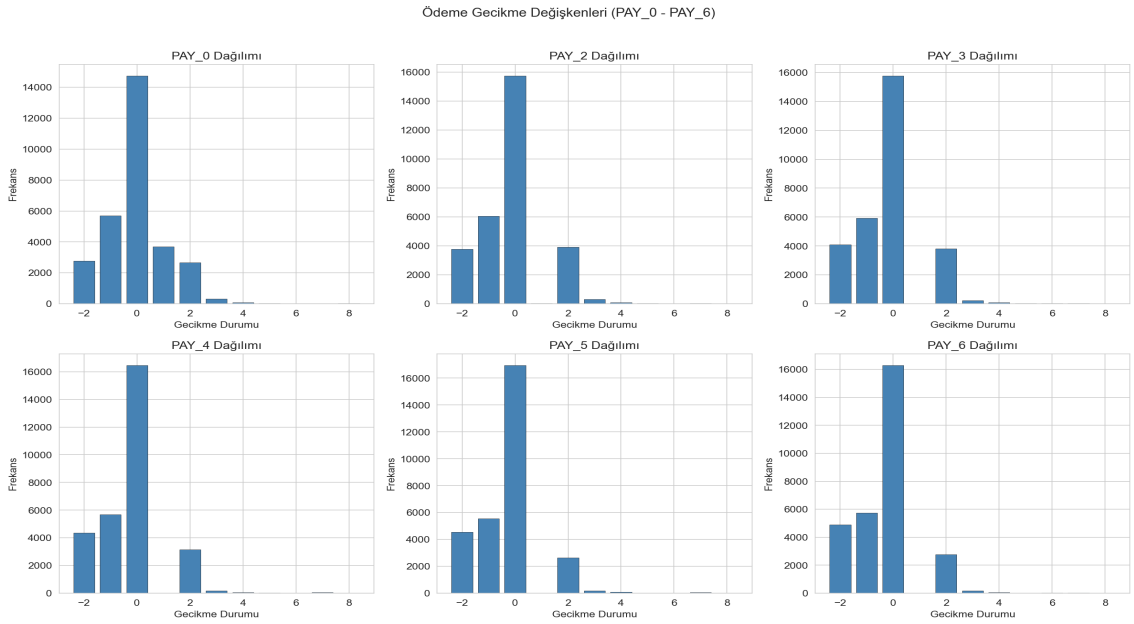


Sekil 3.2: Cinsiyet, egitim ve medeni duruma gore default oranlari

Demografik degiskenler tek baslarina guclu bir risk sinyali degildir. Ancak yine de bazi patternler goruyoruz: Erkeklerde default orani kadinlara gore biraz daha yuksektir. Egitim seviyesi arttikca default orani dusme egilimindedir.

3.3 Odeme Gecikme Gecmisi

Odeme gecikme gecmisi, kredi riski modellemesinin 'altin degiskenidir'. Bir musterinin gecmiste borcunu zamaninda odeyip odemedigi, gelecekteki davranisinin en guclu gostergesidir. Bu, hem sezgisel olarak mantiklidir hem de verinin acikca destekledigi bir bulgudur.

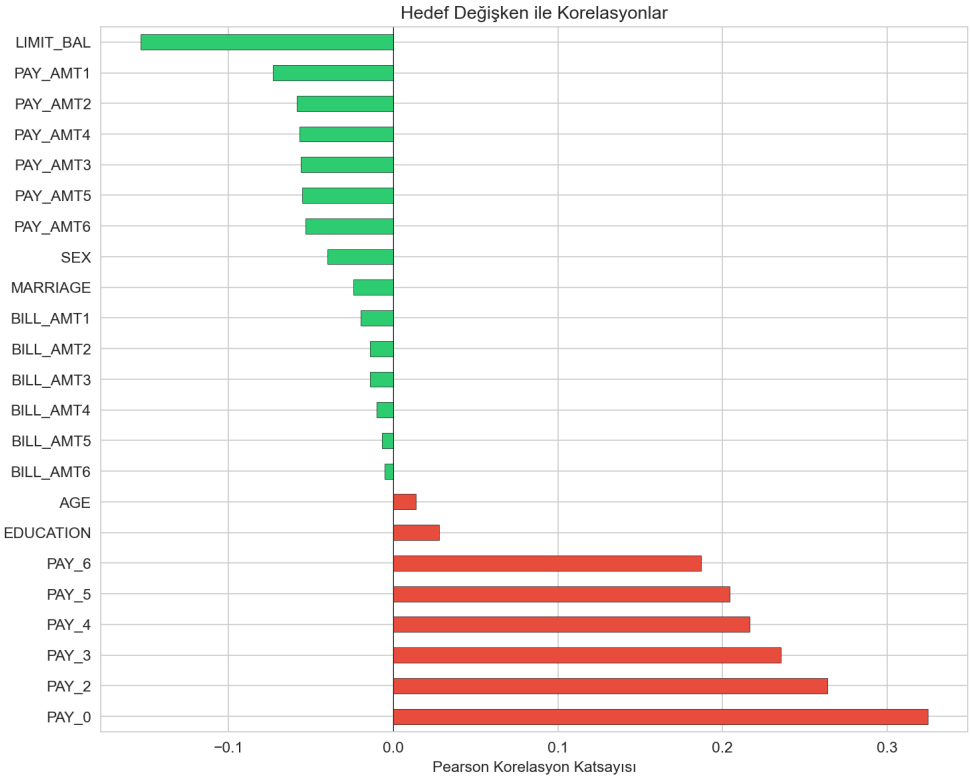


Sekil 3.3: 6 aylik odeme gecikme degiskenlerinin dagilimi

Grafiklerde gorunuyor ki musterilerin buyuk cogunlugu zamaninda odeme yapan (deger -1 veya -2) musteri grubundadir. Ancak gecikme yasayanlarin default oranlari dramatik sekilde yukselir.

3.4 Korelasyon Analizi

Korelasyon, iki degisken arasindaki dogrusal iliskinin gucunu olcer. +1 mukemmel pozitif iliski, -1 mukemmel negatif iliski, 0 ise iliski yoklugu anlamina gelir.



Sekil 3.4: Degiskenlerin hedef degisken (default) ile korelasyonlari

En guclu sinyaller: PAY_0 (son ay gecikme durumu) en yuksek pozitif korelasyona sahip. LIMIT_BAL ise negatif korelasyona sahip (yuksek limit = dusuk risk). BILL_AMT degiskenleri kendi aralarinda cok yuksek korelasyona sahip (multikolinearite). Bu, modelleme sirasinda dikkate alinmasi gereken bir durumdur.

4. SQL ile Segment Analizleri

Bankacilik sektorunde SQL, veri analizinin temel aracidir. Bu projede DuckDB kullanarak segment bazli analizler yaptik. Asagida en onemli bulgulari ozetliyoruz.

4.1 Limit Bandina Gore Default Orani

Musterileri kredi limitine gore gruplara ayirdigimizda cok net bir pattern goruyoruz:

Limit Bandi	Musteri Sayisi	Default Orani	Yorum
< 50K	~5,500	~%30+	En yuksek risk grubu
50K - 100K	~6,500	~%25	Yuksek risk
100K - 200K	~8,000	~%22	Ortalama risk
200K - 500K	~8,000	~%16	Dusuk risk
500K+	~2,000	~%10	En dusuk risk grubu

Limit arttikca default orani belirgin sekilde dusuyor. Bu beklenen bir sonuctur cunku banka zaten daha guvenilir musterilere yuksek limit verir.

4.2 Gecikme Durumu ve Default Iliskisi

En son ayin gecikme durumuna (PAY_0) gore default oranlarini inceledigimizde:

Gecikme Durumu	Anlami	Default Orani	Yorum
-2, -1	Hesap yok / Zamaninda	~%12-15	Dusuk risk
0	Asgari odeme (revolver)	~%18	Orta risk
1	1 ay gecikme	~%35	Yuksek risk
2	2 ay gecikme	~%65	Cok yuksek risk
3+	3+ ay gecikme	~%75+	Neredeyse kesin default

> ***Kritik bulgu:*** *2+ ay gecikme yasayan musterilerin %65-75'i default ediyor. Bu, gecikme gecmisinin ne kadar guclu bir sinyal oldugunu gosteriyor. Ayrica bu, "ardisik gecikme" patterninin tek seferlik gecikmeden cok daha tehlikeli oldugunu ortaya koyuyor.*

4.3 Capraz Analiz: Limit x Gecikme

Iki degiskeni bir arada inceledigimizde daha zengin icgoruler elde ederiz. Dusuk limitli ve gecikmeli musteriler en yuksek risk grubunu olusturur. Yuksek limitli ve gecikmesiz musteriler ise en dusuk riski tasir.

Limit Bandi	Gecikme Yok	1 Ay Gecikme	2+ Ay Gecikme
Dusuk Limit	~%20	~%45	~%75+
Orta Limit	~%14	~%35	~%60

Limit Bandi	Gecikme Yok	1 Ay Gecikme	2+ Ay Gecikme
Yuksek Limit	~%8	~%25	~%50

5. Feature Engineering (Degisken Turetme)

5.1 Feature Engineering Nedir?

Feature engineering, ham veri uzerinden yeni ve daha anlamli degiskenler turetme islemidir. Bunu su benzetmeyle dusunebilirsiniz: Ham veri bir evin malzemeleridir (tugla, cimento, demir). Feature engineering ise bu malzemelerden duvar, kolon ve cati yapmaktir. Model, malzemelerle degil, yapilarla daha iyi calisir.

Iyi feature engineering, model performansini onemli olcude artirabilir. Bazen daha karmasik bir model kullanmak yerine, daha iyi degiskenler turetmek cok daha etkili olabilir.

5.2 Veri Temizleme

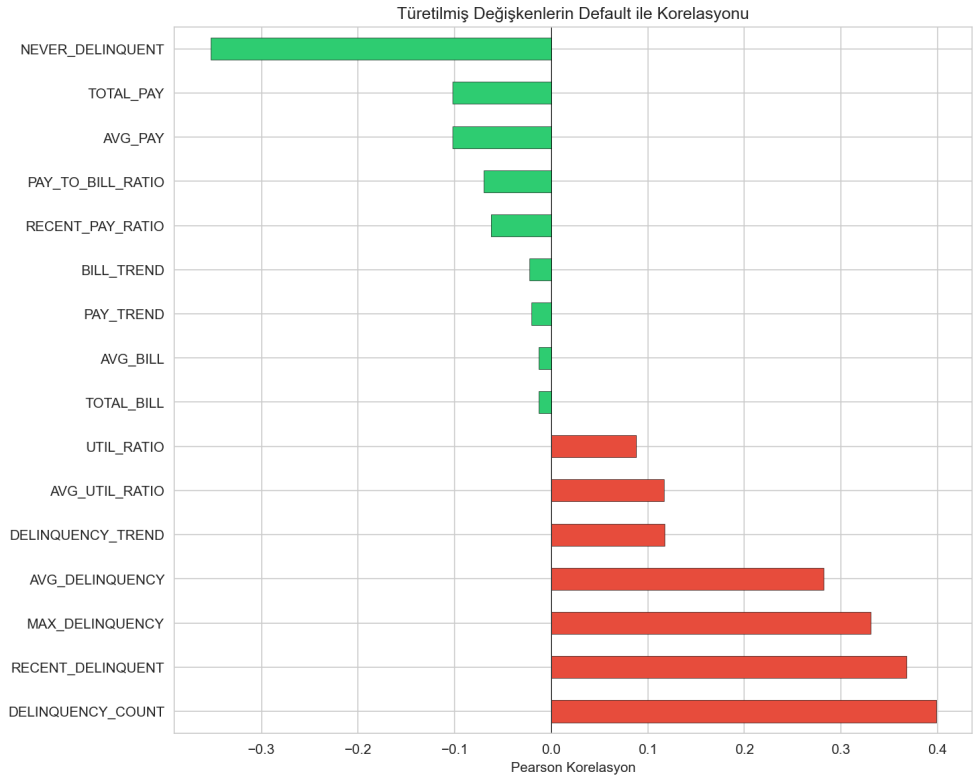
Modellemeye baslamadan once veri kalitesi sorunlarini giderdik:

- **EDUCATION degiskeni:** 0, 5, 6 gibi belgelenmemis degerler 'Diger' (4) olarak birlesitirildi
- **MARRIAGE degiskeni:** 0 degeri 'Diger' (3) olarak islendi
- **Hedef degisken:** 'default payment next month' → 'DEFAULT_FLAG' olarak yeniden adlandirildi

5.3 Olusturulan Degiskenler

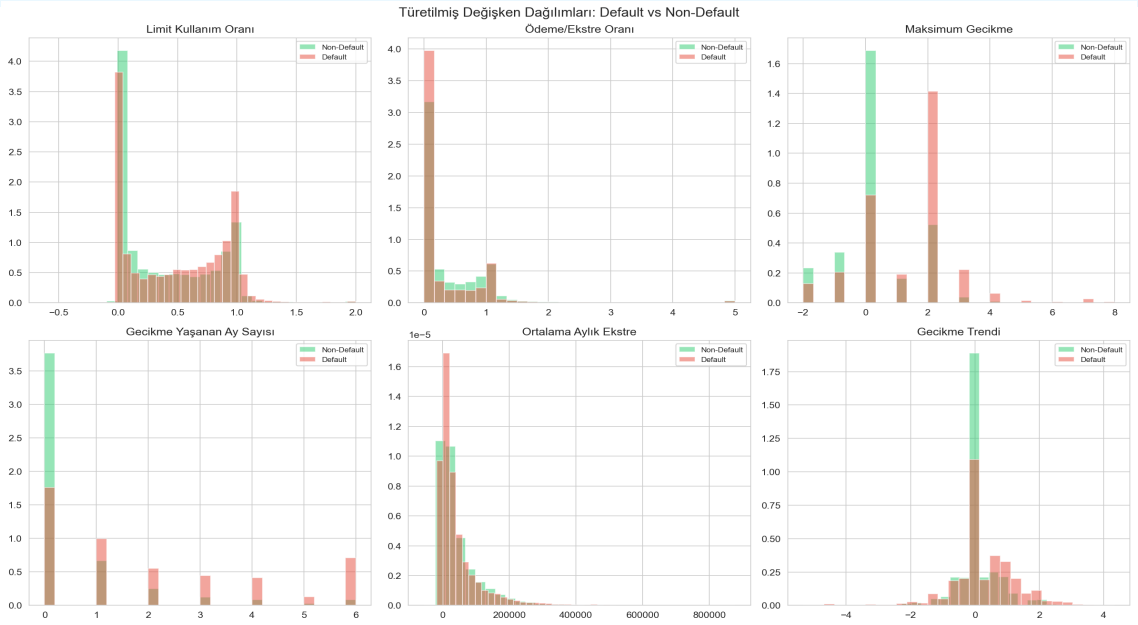
Toplam 16 yeni degisken turettik. Her biri is bilgisine (domain knowledge) dayanarak secilmistir:

Degisken	Aciklama	Is Mantigi
MAX_DELINQUENCY	6 aydaki maks. gecikme	En kotusunu yakalar
AVG_DELINQUENCY	6 aydaki ort. gecikme	Genel gecikme egilimi
DELINQUENCY_COUNT	Gecikme yasanan ay sayisi	Tekrarlilik olcer
NEVER_DELINQUENT	Hic gecikme var mi? (0/1)	Temiz gecmis bayragi
RECENT_DELINQUENT	Son ay gecikmeli mi? (0/1)	Guncel risk
TOTAL_BILL	6 ay toplam ekstre	Harcama davranisi
TOTAL_PAY	6 ay toplam odeme	Odeme davranisi
PAY_TO_BILL_RATIO	Odeme / Ekstre orani	Odeme disiplini
RECENT_PAY_RATIO	Son ay odeme/ekstre	Guncel odeme davranisi
UTIL_RATIO	Son ay ekstre / Limit	Limit kullanim orani
AVG_UTIL_RATIO	6 ay ort. ekstre / Limit	Genel kullanim
BILL_TREND	Ekstre trendi (son 3 - onceki 3)	Harcama degisimi
PAY_TREND	Odeme trendi	Odeme degisimi
DELINQUENCY_TREND	Gecikme trendi	Kotu yonde gidis var mi?



Sekil 5.1: Turetilmis degiskenlerin default ile korelasyonlari

***Onemli bulgu:** Turettigimiz gecikme degiskenleri (MAX_DELINQUENCY, DELINQUENCY_COUNT) orijinal PAY degiskenlerinden daha guclu korelasyon gosteriyor. Bu, feature engineering'in katma degerini acikca ortaya koyuyor.*



Sekil 5.2: Turetilmis degiskenlerin default vs non-default dagilim karsilastirmasi

6. Model Gelistirme

6.1 Neden Iki Model Kuruyoruz? (Champion-Challenger)

Bankacilik sektorunde 'champion-challenger' yaklasimi standart bir pratiktir. Su sekilde calisir:

Champion (Ana Model): Uretimde kullanilan, genellikle daha basit ve yorumlanabilir model. Bu projede Logistic Regression.

Challenger (Yarismaci Model): Champion'a meydan okuyan, genellikle daha karmasik model. Bu projede XGBoost.

Amac sadece 'hangisi daha yuksek skor aliyor?' degil. Gercek soru sudur: 'Daha karmasik model, yorumlanabilirlik kaybini haklilastiracak kadar anlamli bir performans artisi sagliyor mu?' Bankalar, regulator beklentiler nedeniyle genellikle yorumlanabilir modelleri tercih eder.

6.2 Logistic Regression (Ana Model)

Logistic Regression, istatistigin en temel ve en guclu araclarindan biridir. Ikili siniflandirma problemleri (evet/hayir, default/non-default) icin tasarlanmistir.

Nasil calisir? (Basit anlatim)

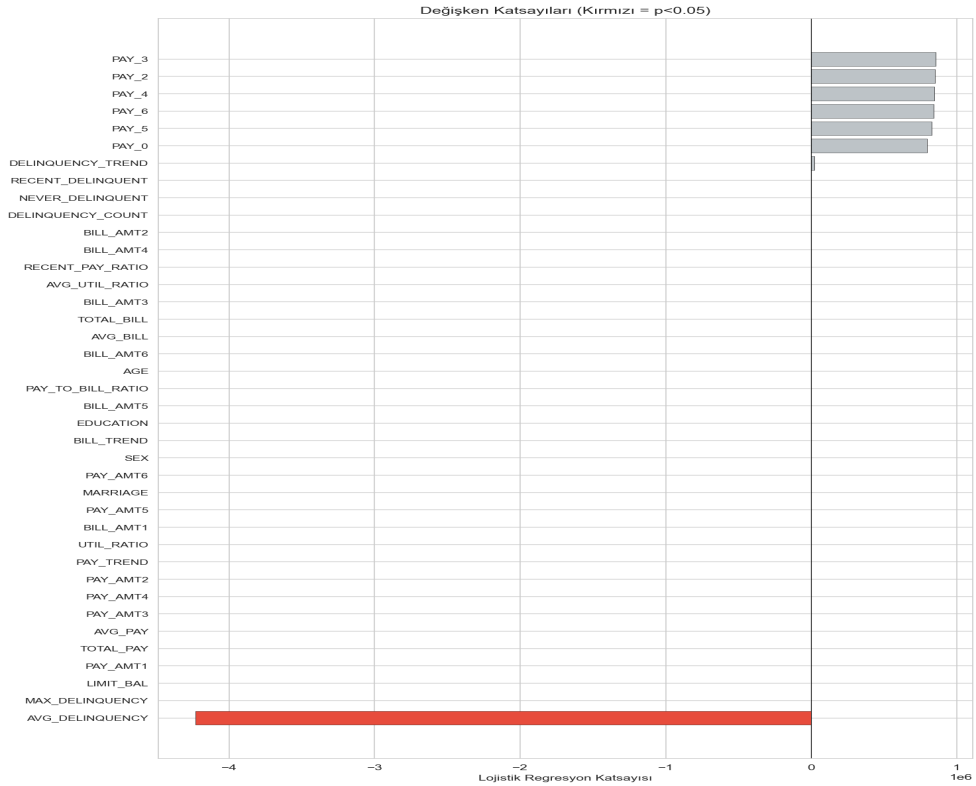
Her degiskenin bir 'agirligi' (katsayi) vardir. Model, tum degiskenleri agirliklariyla carpip toplar ve sonucu 0-1 araliginda bir olasiliga donusturur. Ornegin:

Skor = 0.5 x (gecikme durumu) - 0.3 x (limit) + 0.2 x (yas) + ...

Bu skor daha sonra 'sigmoid fonksiyonu' ile 0-1 arasina sikitirilir. Sonuc: her musteriye %0 ile %100 arasinda bir default olasiligi atanir.

Neden tercih edilir?

- **Yorumlanabilirlik:** Her degiskenin etkisi dogrudan okunabilir. 'Gecikme 1 birim artarsa risk %X artar' denilebilir.
- **Regulator uyumluluk:** Basel III ve BDDK, modelin 'kara kutu' olmamasini ister. LR bunu saglar.
- **Stabilite:** Kucuk veri degisikliklerinde model dramtik sekilde degismez.
- **Hiz:** Cok hizli egitilir ve tahmin uretir. Milyonlarca musteriye saniyeler icinde skor atanabilir.



Sekil 6.1: Logistic Regression katsayilari (kirmizi = istatistiksel olarak anlamli, p<0.05)

6.3 XGBoost (Challenger Model)

XGBoost (Extreme Gradient Boosting), makine ogrenmesinin en basarili algoritmalarindan biridir. Kaggle yarismalarin en cok kazanan algoritmasi olarak bilinir.

Nasil calisir? (Basit anlatim)

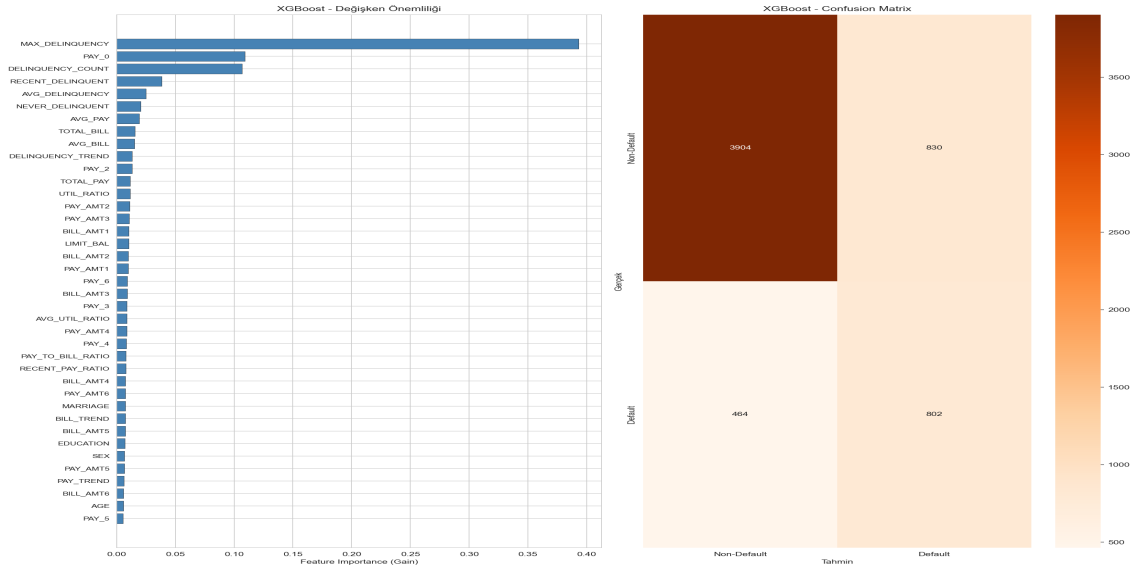
XGBoost, yuzlerce kucuk 'karar agaci' (decision tree) olusturur. Her agac, onceki agacin hatalarini duzeltmeye calisir. Bunlarin hepsini birlestirerek guclu bir tahmin olusturur. Bunu su sekilde dusunebilirsiniz: bir ogrenci sinava giriyor ve hatalarini gozden gecirerek her seferinde daha iyi bir performans sergiliyor.

Avantajlari:

- Non-linear (dogrusal olmayan) iliskileri yakalayabilir
- Degiskenler arasi etkilesimleri otomatik olarak ogrenebilir
- Genellikle daha yuksek tahmin dogrulugu

Dezavantajlari:

- Yorumlanabilirlik dusuk ('kara kutu' olarak algilanabilir)
- Overfit (asiri uyum) riski daha yuksek
- Regulator baski altinda aciklanmasi zor olabilir



Sekil 6.2: XGBoost degisken onemliligi ve confusion matrix

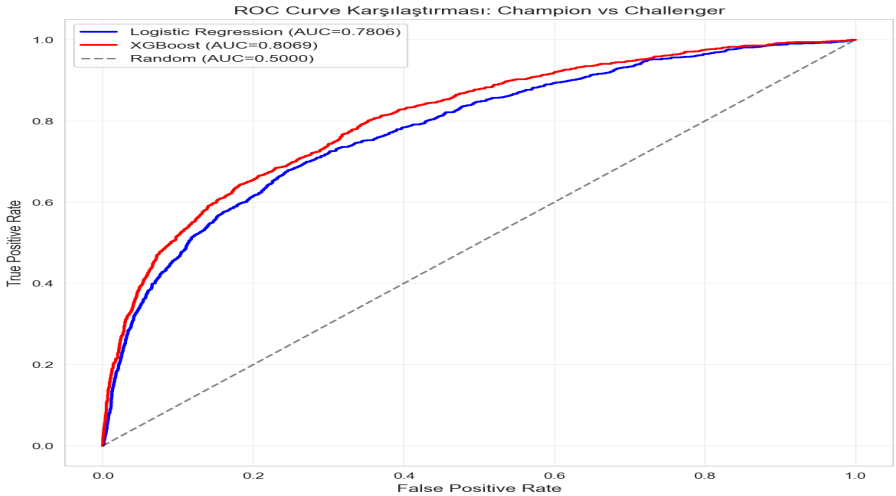
6.4 Train / Test Ayirimi

Modeli egitirken veriyi ikiye ayirdik: egitim seti (%80, 24.000 musteri) ve test seti (%20, 6.000 musteri). Onemli olan nokta, ID sirasini zaman proxysi olarak kullanmamizdir. Yani dusuk ID'li (eski) musteriler egitimde, yuksek ID'li (yeni) musteriler testte. Buna 'quasi out-of-time' split denir.

> ***Neden bu onemli?*** *Gercek hayatta model gecmis verilerle egitilir ve gelecekteki musterilere uygulanir. Rastgele split yerine zaman bazli split, modelin gercek performansini daha iyi simule eder.*

6.5 Model Performans Karsilastirmasi

Metrik	Logistic Regression	XGBoost	Kazanan
Test AUC	0.7806	0.8069	XGBoost
Gini	0.5613	0.6138	XGBoost
Yorumlanabilirlik	Yuksek	Dusuk	LR
Regulator Uyumluluk	Evet	Ek aciklama gerekir	LR
Overfit Riski	Dusuk	Daha yuksek	LR



Sekil 6.3: ROC Curve karsilastirmasi - Champion (LR) vs Challenger (XGBoost)

7. Model Validasyonu

Bu bolum, projenin en kritik kismidir. Modeli 7 farkli boyutta degerlendirerek guclu ve zayif yonlerini ortaya koyuyoruz.

7.1 Ayristirma Gucu (Discrimination)

Ayristirma gucu, modelin 'iyi' ve 'kotu' musterileri birbirinden ne kadar iyi ayirabildigini olcer. Uc temel metrikle degerlendirdik:

ROC-AUC (Area Under the ROC Curve)

ROC-AUC, modelin ayristirma gucunun en yaygin olcusudur. 0.5 ile 1.0 arasinda deger alir:

- 0.50 = Rastgele tahmin (yazin tura atmak gibi - hicbir deger katmaz)
- 0.60-0.70 = Zayif ayristirma
- 0.70-0.80 = Kabul edilebilir (cogu bankacilik uygulamasi icin yeterli)
- 0.80-0.90 = Iyi
- 0.90+ = Cok iyi (pratikte nadiren ulasilir)

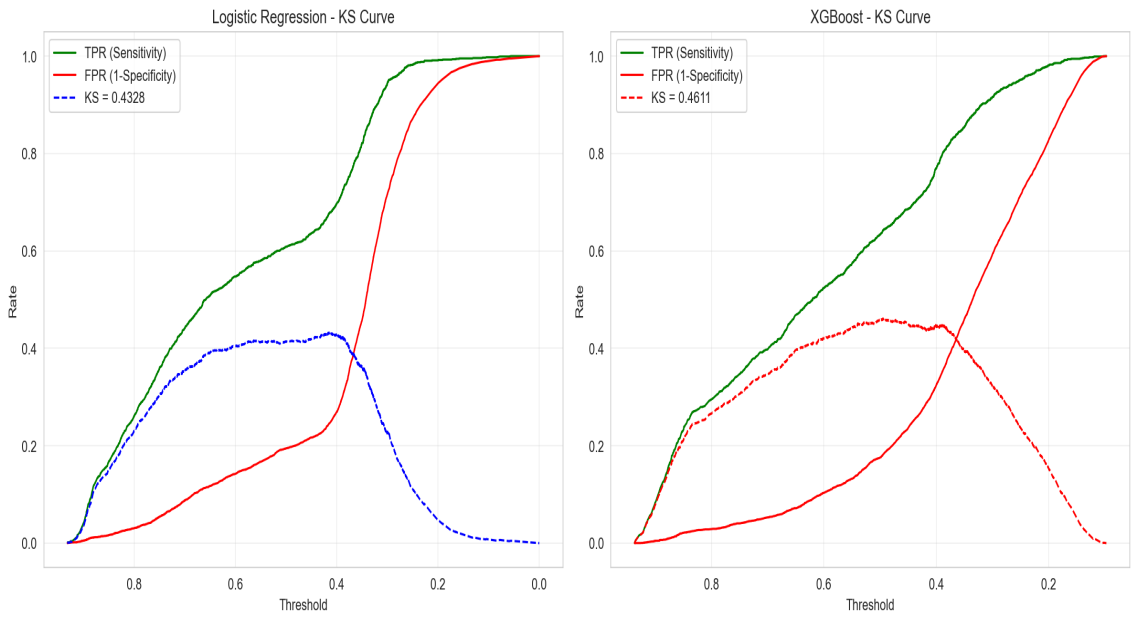
Bu projede LR: 0.7806, XGBoost: 0.8069 AUC elde ettik. Her ikisi de "kabul edilebilir" bandindadir.

Gini Katsayisi

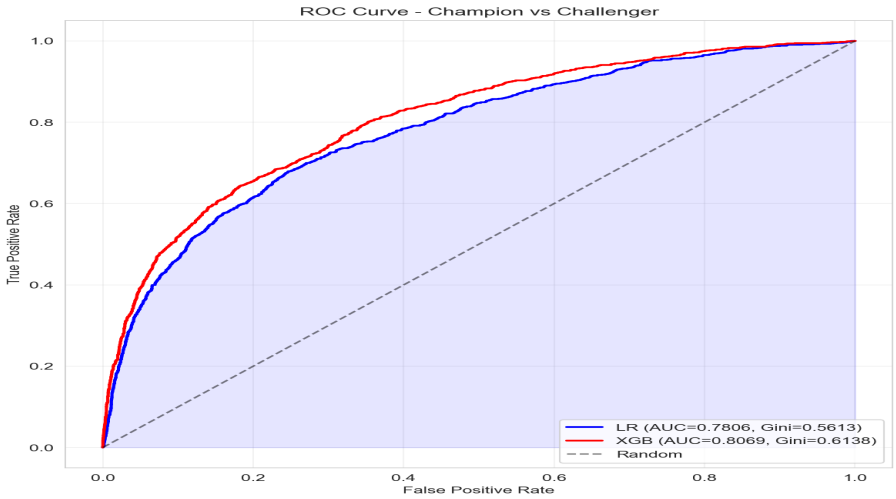
Gini = 2 x AUC - 1 formuluyle hesaplanir. 0 ile 1 arasinda deger alir. AUC'nin alternatif bir ifadesidir. Bankacilik sektorunde AUC yerine Gini kullanilmasi daha yaygindir. Gini > 0.40 genellikle 'iyi' kabul edilir.

KS Istatistigi (Kolmogorov-Smirnov)

KS istatistigi, default ve non-default gruplarin kumulatif dagilim farkinin maksimumunu olcer. Basitce soylersek: 'model iki grubu en cok hangi noktada ayiriyor?' sorusunu cevaplar. KS > 0.30 genellikle iyi kabul edilir.



Sekil 7.1: KS egrileri - LR ve XGBoost



Sekil 7.2: ROC curve karsilastirmasi (detayli)

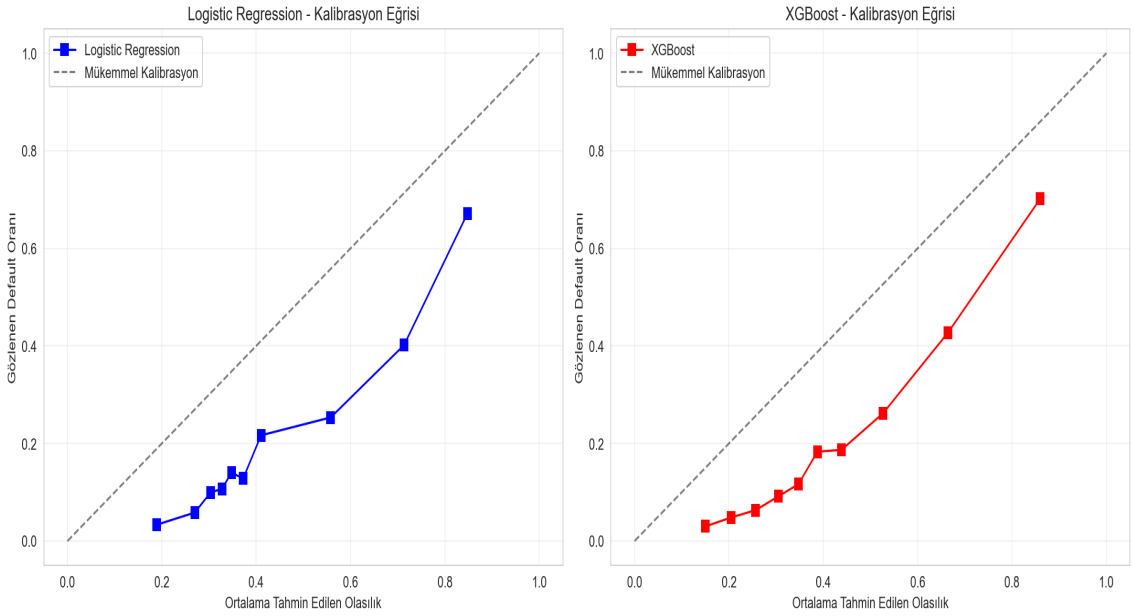
7.2 Kalibrasyon Analizi

Kalibrasyon, modelin urettigi olasiklarin gercekci olup olmadigini olcer. Bu cok onemli bir kavramdir. Ornek verelim:

Model 1000 musteriye '%30 default olasiligi' atadi diyelim. Eger bu 1000 musteriden gercekten ~300'u default ediyorsa, model iyi kalibre edilmistir. Eger gercekte 100 veya 500 kisi default ediyorsa, model kotu kalibre edilmistir.

> ***Neden onemli?*** *Kalibrasyon ozellikle fiyatlandirma ve sermaye hesaplamalari icin kritiktir. Eger model riskleri oldugundan yuksek gosteriyorsa, banka gereginden fazla sermaye ayirir (karlilik duser). Dusuk gosteriyorsa, sermaye yetersiz kalir (risk artar).*

Brier Score: Olasilik tahminlerinin ortalama kare hatasidir. 0'a ne kadar yakinsa o kadar iyi. 0.25'in altindaki degerler genellikle kabul edilebilir.



Sekil 7.3: Kalibrasyon egrileri - tahmin vs gozlem

Grafiklerde kesikli cizgi mukemmel kalibrasyonu temsil eder. Noktalarin bu cizgiye yakin olmasi, modelin iyi kalibre edildigini gosterir.

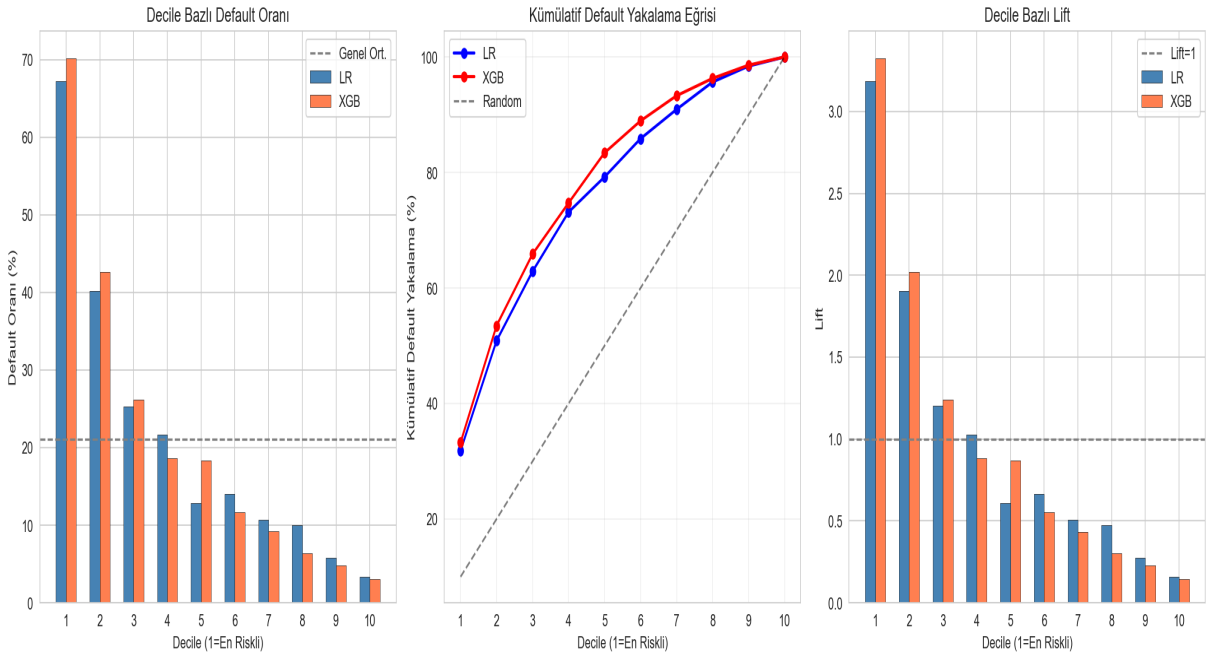
7.3 Decile (Ondalik) Analizi

Decile analizi, modelin pratikte ne kadar kullanisli oldugunu gosterir. Musterileri model skoruna gore 10 esit gruba (decile) ayiririz:

Decile 1 = En riskli %10 musteri, Decile 10 = En az riskli %10 musteri.

Iyi bir modelde, Decile 1'deki default orani cok yuksek, Decile 10'daki ise cok dusuk olmalidir. Monoton azalan bir grafik gormek isteriz.

Lift: Her decile'deki default oraninin genel ortalamaya orani. Ornegin Lift=3.0, bu decile'de default oraninin genel ortalaminin 3 kati oldugunu gosterir.

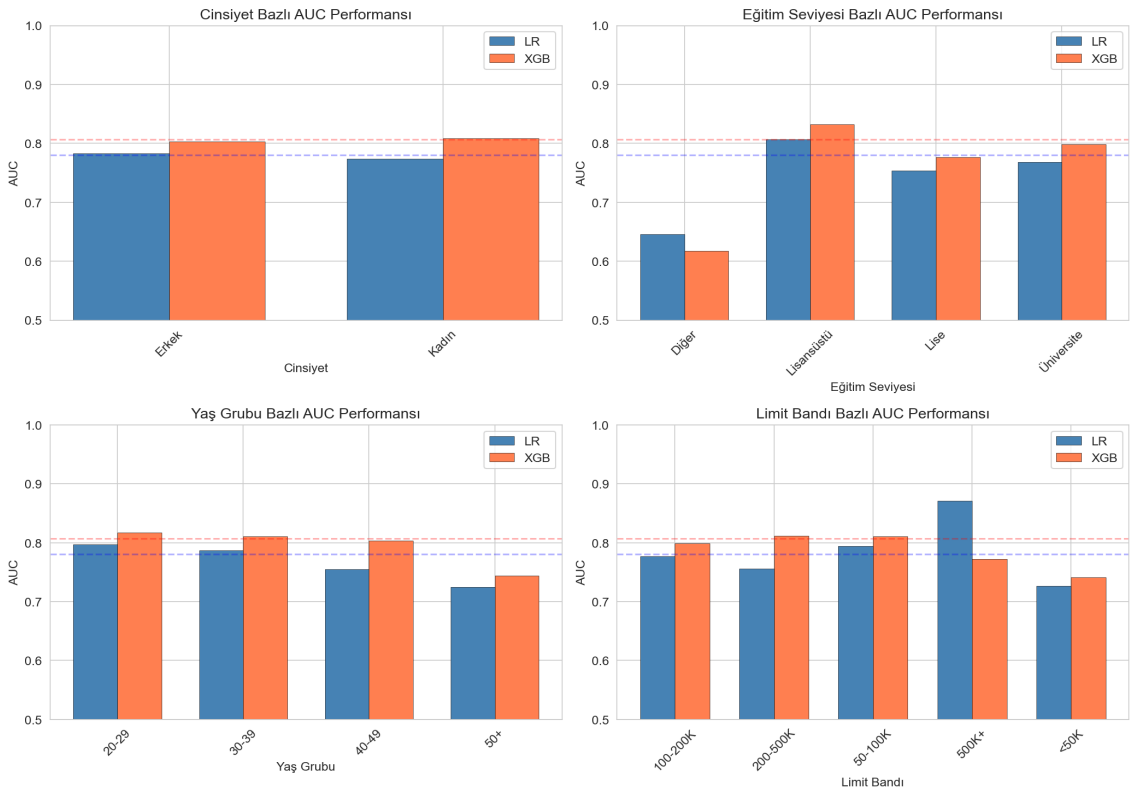


Sekil 7.4: Decile analizi - default orani, kumulatif yakalama, lift

Sol grafik: En riskli decile'de default orani %40-50 civarindayken, en az riskli decile'de %5-8 civarindadir. Model risk siralamasini basariyla yapabiliyor. Orta grafik: En riskli %30 musteri (3 decile), tum defaultlarin %60-65'ini yakaliyor.

7.4 Segment Bazli Performans

Modelin farkli musteri segmentlerinde tutarli calisip calismadigi cok onemlidir. Bir model genel olarak iyi gorunse bile, belirli bir grupta (ornegin genc musteriler) cok zayif olabilir. Bu, hem is riski hem de adillik (fairness) acisindan sorunludur.



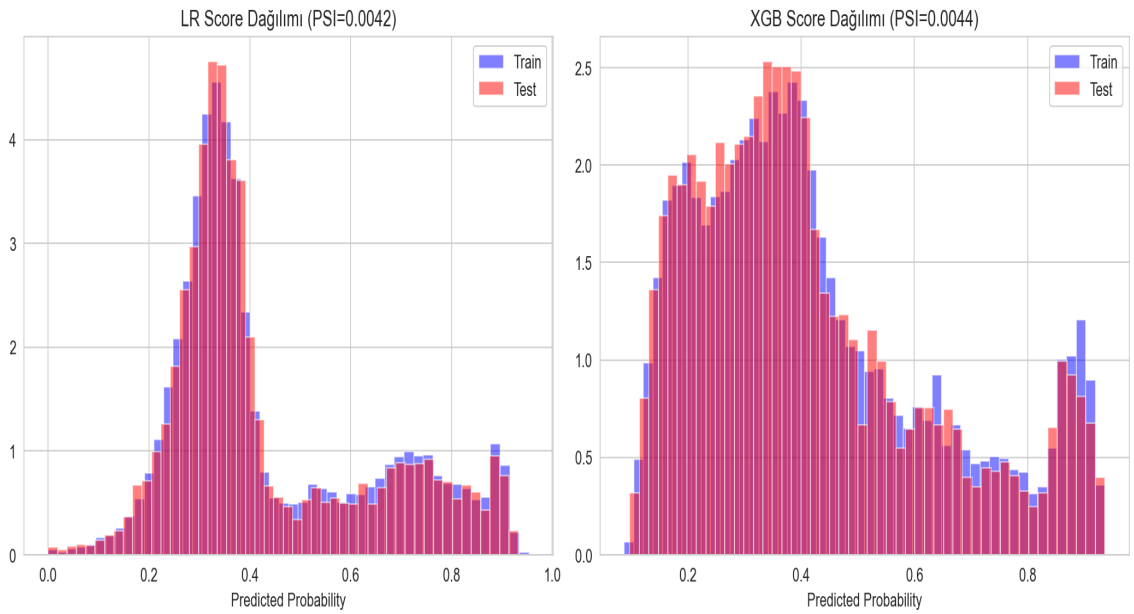
Sekil 7.5: Segment bazli AUC performansi (cinsiyet, egitim, yas, limit)

Grafiklerde kesikli cizgiler genel AUC degerlerini gosterir. Barlarin bu cizgilere yakin olmasi, modelin segmentler arasinda tutarli calistigini gosterir. Belirgin sapmalar varsa, o segmentte model zayif demektir.

7.5 Kararlilik Analizi (PSI - Population Stability Index)

PSI, modelin egitildigi popülasyonla uygulandigi populasyon arasindaki 'kaymayi' (drift) olcer. Zamanla musteriler degisir, ekonomik kosullar degisir. PSI, modelin hala gecerli olup olmadigini izlememizi saglar.

PSI Degeri	Yorum	Aksiyon
< 0.10	Kararli, degisiklik yok	Izlemeye devam
0.10 - 0.25	Hafif kayma	Yakindan izle, nedenini arastir
> 0.25	Belirgin kayma	Model yeniden degerlendirilmeli



Sekil 7.6: Score dagilimi karsilastirmasi (Train vs Test)

Grafiklerde mavi (train) ve kirmizi (test) dagilimlarin birbirine yakin olmasi kararliligi gosterir. PSI degeri dusukse model kararlidir.

8. SHAP ile Model Yorumlama

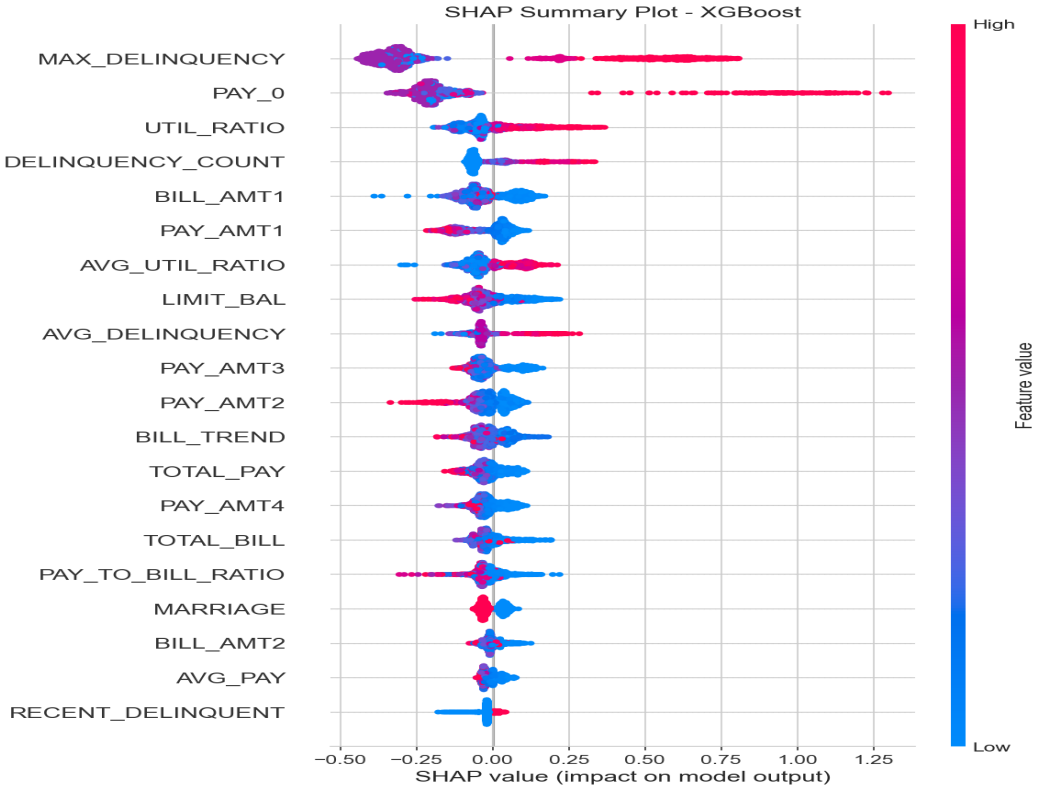
8.1 SHAP Nedir?

SHAP (SHapley Additive exPlanations), oyun teorisinden esinlenen bir model yorumlama yontemidir. Her bir degiskenin, her bir tahmin icin ne kadar katki yaptigini olcer.

Basitce soylersek: 'Bu musteri icin default olasiligi %35 cikti. Peki bu %35'in ne kadari gecikme gecmisinden, ne kadari limitten, ne kadari yastan kaynaklaniyor?' sorusunu cevaplar.

> ***Neden onemli?*** *Ozellikle XGBoost gibi "kara kutu" modellerde, SHAP regulatorlerin "modeli aciklayabilir misiniz?" sorusuna cevap vermemizi saglar. Bir musteriye "kredi talebiniz reddedildi" dendiginde, sebebini aciklayabilmek hem yasal bir gereklilik hem de musteri guvenini saglar.*

8.2 SHAP Ozet Grafigi (Summary Plot)

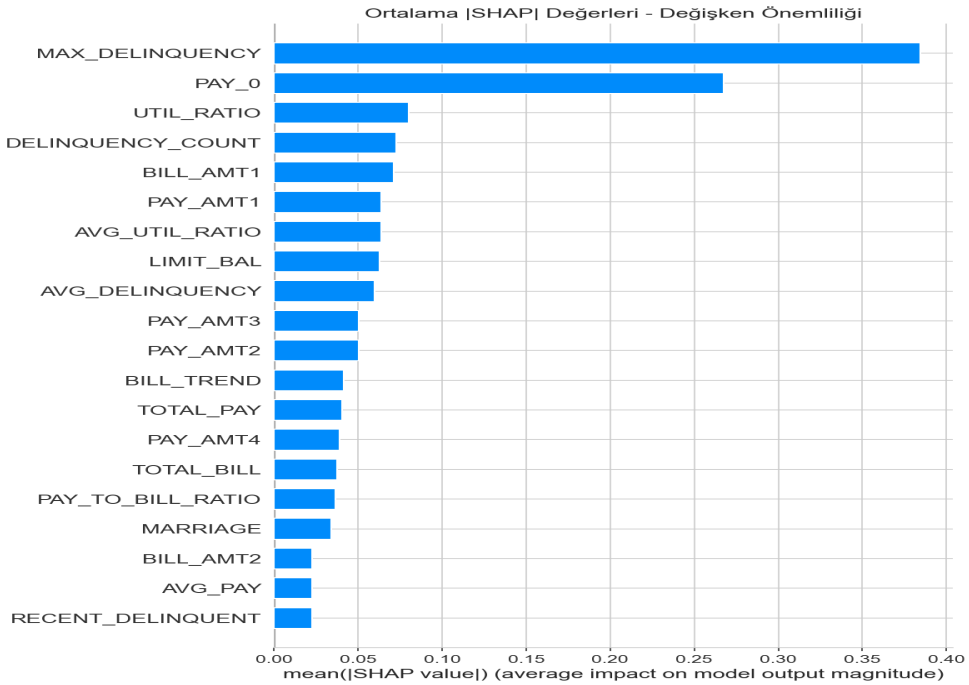


Sekil 8.1: SHAP summary plot - her noktanin rengi degiskenin degerini (kirmizi=yuksek, mavi=dusuk) gosterir

Bu grafik nasil okunur? Her satir bir degiskeni temsil eder. Noktalar musterileri gosterir. Saga giden noktalar default olasiligini artiran, sola gidenler azaltan etkileri gosterir. Renk ise degiskenin degerini belirtir: kirmizi = yuksek deger, mavi = dusuk deger.

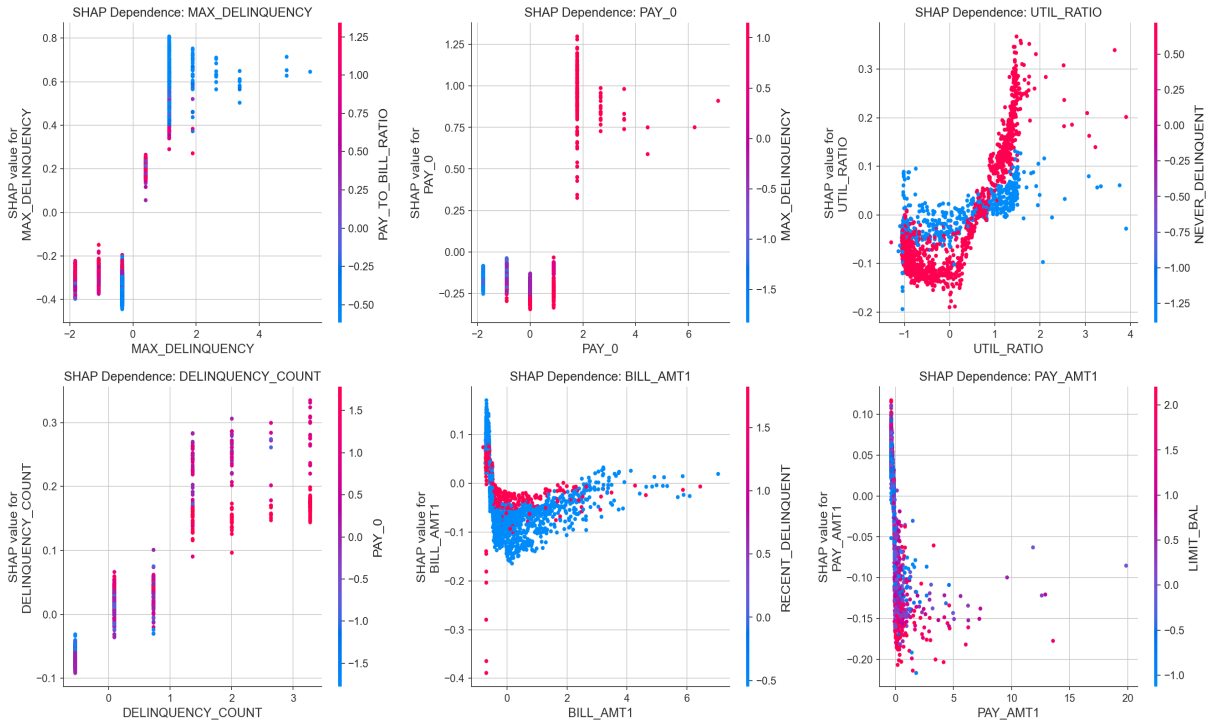
Ornegin PAY_0 (son ay gecikme) icin: Kirmizi noktalar (yuksek gecikme) saga gidiyor → yuksek gecikme default riskini artiriyor. LIMIT_BAL icin: Mavi noktalar (dusuk limit) saga gidiyor → dusuk limit default riskini artiriyor.

8.3 Degisken Onemliligi (SHAP Barplot)



Sekil 8.2: Ortalama |SHAP| degerleri - degiskenlerin genel onemliligi

8.4 Bagimsizlik Grafikleri (Dependence Plots)



Sekil 8.3: En onemli 6 degisken icin SHAP dependence plotlari

Bu grafikler, her degiskenin degeri degistikce SHAP katisisinin nasil degistigini gosterir. Ornegin PAY_0 arttikca SHAP degeri de artar (risk artar). LIMIT_BAL arttikca SHAP degeri duser (risk azalir). Non-linear iliskiler de bu grafiklerde gorulebilir.

9. Bulgular ve Oneriler

9.1 Temel Bulgular

• **En guclu risk sinyali odeme gecikme gecmisidir.** PAY_0 (son ay gecikme durumu) hem korelasyon hem SHAP analizinde en belirleyici degisken. 2+ ay gecikme yasayan musterilerin %65-75'i default ediyor.

• **Limit kullanim orani ikinci en guclu sinyaldir.** Limitinin %70'inden fazlasini kullanan ve gecikme yasayan musteriler en yuksek risk grubunu olusturuyor.

• **Feature engineering belirgin katma deger yaratmistir.** Turettigimiz MAX_DELINQUENCY ve DELINQUENCY_COUNT degiskenleri, orijinal PAY degiskenlerinden daha guclu sinyaller uretmistir.

• **Her iki model de kabul edilebilir performans sergilemistir.** LR Test AUC: 0.7806, XGBoost Test AUC: 0.8069. XGBoost ~2.6 puan daha yuksek AUC elde etmistir.

• **Logistic Regression champion model olarak onerilir.** Yorumlanabilirlik, regulator uyumluluk ve kararlilik avantajlari, XGBoost'un marjinal performans artisina ustun gelir.

9.2 Sinirlamalar

• Veri tek bir ulke ve donem verisine dayanmaktadir (Tayvan, 2005). Turkiye banka musterilerine dogrudan uygulanabilirlik sinirlidir.

• Zaman boyutu sinirlidir (6 aylik gozlem penceresi). Makroekonomik donguler yakalanamaz.

• Gercek uretim ortami gozlenmemistir. Sonuclar akademik cercevede degerlendirilmelidir.

• Model karar destegi uretir; tek basina kredi tahsis karari vermez. Insan gozetimi (human-in-the-loop) zorunludur.

• Quasi out-of-time split kullanilmistir; ideal olan gercek zaman damgasina dayali split olurdu.

9.3 Oneriler

• **Ana model:** Logistic Regression champion olarak onerilir. Yerel regulator (BDDK) beklentileriyle uyumludur.

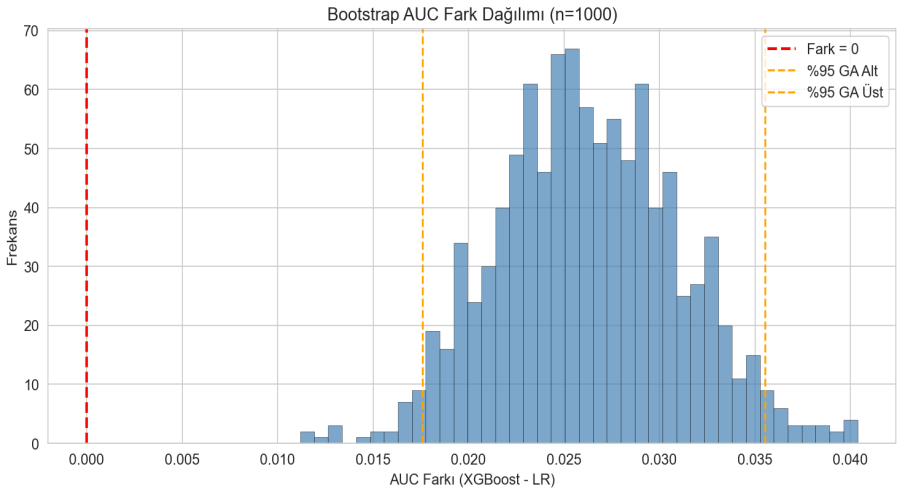
• **Periyodik izleme:** PSI ve AUC metrikleri aylik olarak izlenmeli, PSI > 0.10 uyari esigi belirlenmeli.

• **Segment izleme:** Ozellikle dusuk limitli ve genc musteri segmentlerinde performans yakindan takip edilmeli.

• **Dogrulama:** Model, canli veriye uygulanmadan once bir pilot donemde izlenmeli.

• **Dokumantasyon:** Model metodolojisi, degisken tanimlari ve validasyon bulgulari regulator dosyasina dahil edilmeli.

9.4 Champion vs Challenger Sonuc



Sekil 9.1: Bootstrap AUC fark dagilimi (XGBoost - LR)

Bootstrap testi ile 1000 kez ornekleme yaparak iki model arasindaki AUC farkinin istatistiksel anlamliligi test edildi. Gucen araliginin 0'yi icerip icermemesi, farkin anlamli olup olmadigini belirler.

10. Mulakat Soru-Cevap Rehberi

Asagida, DenizBank Risk Modelleri Validasyon pozisyonu mulakatinda sorulabilecek sorular ve kapsamli cevaplari yer almaktadir.

S1: Kredi riski nedir ve bankalar icin neden onemlidir?

Kredi riski, borc alanin yukumlulugunu yerine getirememesi olasiligini ifade eder. Bankalar icin kritiktir cunku: (1) Ana gelir kaynagi olan faiz geliri, kredilerin geri odenmesine baglidir. (2) Basel III duzenlenmelerine gore kredi riskine karsilik sermaye ayrilmasi zorunludur. (3) Yanlis risk degerlendirmesi hem kar kaybina hem de sistemik riske yol acabilir. 2008 krizi, bu riskin kucumsenmesinin sonucudur. Benim projemde 30,000 kredi karti musterisinin temerut riskini modelledim.

S2: Model validasyonu nedir? Neden model kuran ekipten farkli bir ekip yapar?

Model validasyonu, bir modelin dogrulugunu, uygunlugunu ve sinirlamalarini bagimsiz olarak degerlendirme sureci. Farkli ekip yapar cunku: (1) Bagimsizlik ilkesi — modeli kuran ekip kendi hatalarina karsikisa olabilir. (2) Regulasyon geregi — Basel, BDDK ve SR 11-7 (Fed'in model risk yonetimi rehberi), bagimsiz validasyon gerektirir. (3) Farkli bakis acisi — validasyon ekibi 'model calisiyor mu?' yerine 'model NEREDE calismayabilir?' sorusunu sorar. Projemde modeli 7 farkli boyutta validate ettim: ayristirma gucu, kalibrasyon, decile, segment, kararlilik, yorumlama, champion vs challenger.

S3: ROC-AUC nedir? Nasil yorumlanir?

ROC (Receiver Operating Characteristic) egrisi, modelin farkli esik degerlerinde True Positive Rate ve False Positive Rate arasindaki dengeyi gosterir. AUC (Area Under Curve), bu egrinin altindaki alandir. Rastgele bir model 0.50, mukemmel model 1.00 AUC verir. Bankacilikta 0.70 uzeri kabul edilebilir, 0.80 uzeri iyidir. Projemde LR 0.7806, XGBoost 0.8069 AUC elde etti. Onemli nokta: AUC tek basina yeterli degildir — kalibrasyon, segment performansi ve kararlilik da degerlendirilmelidir.

S4: KS istatistigi ne anlama gelir?

Kolmogorov-Smirnov (KS) istatistigi, default ve non-default gruplarin kumulatif dagilim fonksiyonlari arasindaki maksimum farki olcer. Yani 'model iki grubu en cok hangi noktada ayiriyor?' sorusuna cevap verir. KS > 0.30 genellikle iyi kabul edilir. KS'nin AUC'den farki: AUC tum esik degerleri uzerinden bütünsel performansi olcerken, KS belirli bir noktadaki maksimum ayrismayi gosterir. Ikisi birlikte kullanilmalidir.

S5: Gini katsayisi nedir?

Gini = 2 * AUC - 1. AUC'nin 0-1 araligina normalize edilmis halidir. Bankacilik sektorunde AUC yerine Gini kullanimi daha yaygindir. Gini > 0.40 genellikle iyi, > 0.50 cok iyi kabul edilir. Iktisattan bilinen Gini katsayisiyla (gelir dagilimi) adi ayni olsa da farkli baglam icin kullanilir.

S6: Kalibrasyon nedir ve neden onemlidir?

Kalibrasyon, modelin urettigi olasiklarin gercekci olup olmadigini olcer. Model %30 default olasiligi dediginde, gercekten ~%30 default gozlemlenmeli. Ozellikle su alanlarda kritiktir: (1) Fiyatlandirma — risk primi hesaplamasi dogru olasiklara dayanir. (2) Sermaye hesaplama — Basel formullerinde PD (default olasiligi) dogrudan kullanilir. (3) Karar esigi belirleme — 'risk > %X ise kredi verme' kuralinda

X'in anlamli olmasi icin olasiklarin kalibre olmasi gerekir. Brier Score ile olcuyoruz; 0'a yakin = iyi kalibrasyon.

S7: PSI (Population Stability Index) nedir?

PSI, modelin egitildigi populasyonla uygulandigi populasyon arasindaki dagilim kaymasini olcer. Formulu: PSI = sum((actual% - expected%) * ln(actual%/expected%)). PSI < 0.10: kararli, 0.10-0.25: izlenmeli, > 0.25: model yeniden degerlendirilmeli. Pratikte: musterilerin profili zamanla degisir, ekonomi degisir, rekabet degisir. PSI bize 'model hala gecerli mi?' sorusunu cevaplamamiza yardimci olur. Projemde hem score PSI'i hem de feature PSI'i (her degiskenin dagilim kaymasi) hesapladim.

S8: Logistic Regression neden bankacilikta tercih edilir?

Uc temel neden: (1) Yorumlanabilirlik — her katsayi dogrudan risk faktoru olarak okunur, 'gecikme 1 birim artarsa odds %X artar' gibi. (2) Regulator uyumluluk — Basel III ve BDDK, modelin aciklanabilir olmasini ister; LR 'kara kutu' degildir. (3) Kararlilik — kucuk veri degisikliklerinde model dramatik sekilde degismez. Dezavantajlari: non-linear iliskileri yakalayamaz, degiskenler arasi etkilesimi modelleyemez. Ancak bu dezavantajlar, feature engineering ile kisimen giderilebilir.

S9: XGBoost nedir ve LR'ye kiyasla avantaj/dezavantaji?

XGBoost, gradient boosting tabanli bir ensemble yontemidir. Yuzlerce karar agacini ardiasik egiterek her birinin oncekinin hatasini duzeltmesini saglar. Avantajlari: non-linear iliskiler, otomatik etkilesim, yuksek dogruluk. Dezavantajlari: 'kara kutu' algisi (SHAP ile azaltilir), overfit riski, regulator aciklama zorluklari. Projemde XGBoost, LR'ye kiyasla 2.6 puan daha yuksek AUC elde etti. Ancak champion olarak LR'yi onerdim cunku yorumlanabilirlik ve regulator uyumluluk avantajlari, marjinal performans farkina ustun gelir.

S10: Overfitting nedir ve nasil tespit edilir?

Overfitting, modelin egitim verisini 'ezberlemesi' ve yeni veriye genelleyememe durumudur. Tespit yontemleri: (1) Train-Test AUC farki — fark > 0.05 ise endise verici. (2) Cross-validation — fold'lar arasi yuksek varyans overfit isareti. (3) Learning curve — egitim seti buyudukce test performansi artiyor mu? Onleme yontemleri: regularization (C parametresi), early stopping, cross-validation ile hiperparametre secimi, max_depth sinirlamasi. Projemde LR'nin overfit riski dusuk, XGBoost'un biraz daha yuksek cikti.

S11: Champion-Challenger yaklasimi nedir?

Uretimde kullanilan modele 'champion', ona meydan okuyan yeni modele 'challenger' denir. Amac: (1) Mevcut modelin hala en iyi secim olup olmadigini test etmek. (2) Yeni tekniklerin katma degerini istatistiksel olarak degerlendirmek. (3) Model degisiklik kararlarini kanita dayali almak. Bootstrap AUC fark testi ile iki model arasindaki farkin istatistiksel anlamliligi test edilir. Eger challenger anlamli ustunluk gostermiyorsa, champion'i degistirmeye gerek yoktur.

S12: SHAP nedir ve neden onemlidir?

SHAP (SHapley Additive exPlanations), oyun teorisinden esinlenen bir model yorumlama yontemidir. Her degiskenin her tahmine katisisini olcer. Neden onemli: (1) 'Kara kutu' modelleri aciklanabilir kilar. (2) Musteri ret sebebi aciklamak icin kullanilir ('kredi limitiniz dusuk' gibi). (3) Regulator beklentileri karsilar. (4) Degisken secimi ve feature engineering icin yol gosterir. Projemde XGBoost modelinin SHAP analizini yaptim ve PAY_0'in (son ay gecikme) en etkili degisken oldugunu gosterdim.

S13: Feature engineering nedir ve neden onemlidir?

Ham veriden yeni ve daha anlamli degiskenler turetme islemidir. Onemlidir cunku: (1) Model performansini artirabilir — bazen daha iyi degisken, daha karmasik modelden daha etkilidir. (2) Is bilgisini modele aktarir — 'limit kullanim orani' gibi kavramlar bankacilarin zaten bildigi risk gostergeleridir. (3) Non-linear iliskileri yakalamaya yardimci olur. Projemde 16 turetilmis degisken olusturdum: gecikme turevleri, odeme/ekstre oranlari, limit kullanim orani, trend degiskenleri.

S14: Sinif dengesizligi (class imbalance) nedir ve nasil yonetilir?

Bir sinifin diger siniftan cok daha az gozleme sahip olmasidir. Bu projede %22 default, %78 non-default. Sorun: model azinlik sinifini gormezden gelerek cogunlugun dogrulugunu maksimize etmeye calisabilir. Cozumler: (1) class_weight='balanced' — kayip fonksiyonunda azinlik sinifina daha fazla agirlik verir. (2) scale_pos_weight — XGBoost'un benzeri. (3) SMOTE — yapay azinlik ornegi uretir. (4) Metrik secimi — accuracy yerine AUC, F1, recall kullanilir. Projemde class_weight ve scale_pos_weight kullandim.

S15: Out-of-time validation nedir?

Veriyi zamana gore bolemek. Gecmis verilerle egitip, gelecekteki donemin verisiyle test etmek. Neden onemli: gercek hayatta model gecmisle egitilip gelecege uygulanir. Rastgele split, zaman icindeki degisimleri yakalamaz ve performansi asiri iyimser gosterir. Projemde tam tarih bilgisi olmadigindan, ID sirasini zaman proxysi olarak kullandim (quasi out-of-time split).

S16: Decile analizi nedir ve pratikte nasil kullanilir?

Musterileri model skoruna gore 10 esit gruba (decile) ayirma. Pratikte: (1) Banka, en riskli 2-3 decile'deki musterilere kredi vermez veya daha yuksek faiz uygular. (2) Lift degeri, modelin katma degerini gosterir — Lift=3 demek 'bu grupta risk genel ortalamanin 3 kati'. (3) Kumulatif yakalama orani, 'en riskli %X'i incelersem defaultlarin %Y'sini yakalarim' sorusunu cevaplar. Stratejik musteri yonetimi icin kritiktir.

S17: Basel duzenlemesi nedir ve kredi riski modelleriyle iliskisi?

Basel (I, II, III), bankalarin sermaye yeterliligi ve risk yonetimi icin uluslararasi standartlar butunudur. Kredi riski ile iliskisi: Basel II'nin IRB (Internal Ratings Based) yaklasimi, bankalarin kendi PD (default olasiligi), LGD (kayip orani) ve EAD (risk tutari) modellerini kullanmasina izin verir. Ancak bu modellerin bagimsiz validasyonu zorunludur. Turkiye'de BDDK, Basel uyumlulugunui denetler. Model validasyonu bu duzenlemenin temel bir parcasidir.

S18: SQL bilginizi bu projede nasil kullandiniz?

DuckDB kullanarak 20'den fazla SQL sorgusu yazdim. Ornekler: (1) Segment bazli default orani hesaplama (cinsiyet, yas, egitim, limit bandi). (2) Capraz tablolar (limit x gecikme). (3) Ardisik gecikme profili analizi. (4) Odeme/ekstre orani bazli risk segmentasyonu. SQL, bankacilik sektorunde veri analizinin temel aracidir. Buyuk veri setlerinde hizli segment analizleri yapmak icin zorunludur.

S19: Bu projede karsilastiginiz en buyuk zorluk ne oldu?

Uc temel zorluk: (1) Degisken isimlendirmesi — orijinal veride X1, X2 gibi isimler vardi; is diline cevirmek gercek hayattaki dokumantasyon zorlugunu yansitir. (2) PAY degiskenlerindeki -2, -1, 0 degerlerinin anlamini ciklama — bu degerler belgede tam aciklanmamisti. (3) Quasi out-of-time split tasarimi — tam tarih bilgisi olmadiginden yaratici bir cozum uretmem gerekti. Bu, uretim ortamindaki veri sinirlamalarinin bir simulasyonuydu.

S20: Bu projeyi gercek bir bankada uygulasaydiniz, ne farkli yapardiniaz?

Bircok sey: (1) Gercek out-of-time validation — aylara gore kesin split. (2) Daha fazla degisken — gelir, meslek, sektor, buro skoru, hesap hareketleri. (3) Reject inference — kredi verilmeyen musterilerin de modele dahil edilmesi. (4) Stres testi — kriz senaryolarinda model performansi. (5) A/B test — champion ve challenger'in canli trafikte karsilastirmasi. (6) Model monitoring altyapisi — otomatik PSI izleme, alarm mekanizmasi. (7) Governance sureci — model sahipligi, onay mekanizmasi, dogumetasyon standartlari.

11. Kavram Sozlugu

Kavram	Aciklama
AUC	ROC egrisinin altindaki alan. 0.5-1.0 arasi. Modelin ayristirma gucunu olcer.
Basel III	Bankalarin sermaye yeterliligi icin uluslararasi duzenleme cercevesi.
BDDK	Bankacilik Duzenleme ve Denetleme Kurumu. Turkiyede bankalari denetler.
Brier Score	Olasilik tahminlerinin ortalama kare hatasi. Dusuk=iyi kalibrasyon.
Calibration	Modelin urettigi olasiklarin gercekle uyumu.
Champion	Uretimde aktif olarak kullanilan model.
Challenger	Championa meydan okuyan alternatif model.
Class Imbalance	Hedef degiskenin siniflarinin dengesiz dagildigi durum.
Confusion Matrix	Tahmin vs gercek sinif karsilastirma tablosu (TP, FP, TN, FN).
Cross-Validation	Veriyi K parcaya bolup her birinde test ederek model kararliligini olcme.
Decile	Musterileri skora gore 10 esit gruba ayirma.
Default	Temerut. Borcun geri odenememesi durumu.
Drift	Modelin egitildigi populasyonla uygulama populasyonunun farklilasmasi.
EDA	Kesifsel Veri Analizi. Veriyi modellemeden once anlama sureci.
F1 Score	Precision ve Recallin harmonik ortlamasi.
Feature Engineering	Ham veriden yeni degiskenler turetme islemi.
Gini	2*AUC-1. Ayristirma gucunun alternatif olcusu.
KS	Kolmogorov-Smirnov. Iki grubun kumulatif dagilim farkinin maksimumu.
Lift	Bir gruptaki default oraninin genel ortalamaya orani.
Logistic Regression	Ikili siniflandirma icin yorumlanabilir istatistiksel model.
Multicollinearity	Bagimsiz degiskenlerin birbirleriyle yuksek korelasyona sahip olmasi.
Out-of-Time	Modeli gecmis verilerle egitip gelecek verilerle test etme yaklasimi.
Overfit	Modelin egitim verisini ezberleyip yeni veriye genelleyememesi.
PD	Probability of Default. Temerut olasiligi.
Precision	Model default dediginde ne oranda gercekten default olduklari.
PSI	Population Stability Index. Populasyon kaymasini olcer.
Recall	Gercek defaultlarin ne kadari yakalandi.
ROC Curve	TPR vs FPR grafigi. Modelin ayristirma performansini gorsellestirir.
SHAP	Oyun teorisine dayali model yorumlama yontemi.
XGBoost	Gradient boosting tabanli guclu makine ogrenmesi algoritmasi.

Bu rapor, kredi riski skorlama ve model validasyonu projesinin kapsamli bir dokumantasyonudur. Tum analizler Python, SQL ve acik kaynakli kutuphaneler kullanilarak gerceklestirilmistir.